

개발된 LLM 연동 웹 애플리케이션

제출일자 : 2025.03.17. (월)

작성 팀원 : 신지용, 윤경은, 안혜빈, 문지영

개요	• 목표 사내 규정 판단, 문서 분석/생성, 일정 관리를 지능형 AI 에이전트가 처리하는 업무 자동화 플랫폼 구축 • 주요기능 ◦ 자연어 질의 기반 사내 규정 판단 — 다중 규정 교차 판단 + 근거 조항 + 대안 제시 ◦ 문서 생성(회의록/보고서/제안서) · 요약 · 검색 · QA — 템플릿 기반 DOCX 생성 + RAG 기반 검색 ◦ 일정 등록/조회 + Google Workspace 4종 통합 (Calendar · Tasks · Gmail · Sheets) ◦ Task Pipeline 칸반 보드 + 결재 시스템 + 쪽지 시스템 ◦ LangGraph 기반 멀티 Agent 오케스트레이션 + SSE 실시간 스트리밍 • 기술스택 ◦ 프론트엔드 : React 18 (Vite), Zustand, TanStack Query, Tailwind CSS, FullCalendar ◦ 백엔드 : FastAPI, PostgreSQL, SQLAlchemy + Alembic, Redis, JWT + Google OAuth 2.0 ◦ AI/ML : LangGraph (StateGraph), GPT-4o-mini / Claude Sonnet 4, Kanana-1.5-8B + LoRA (파인튜닝) ◦ RAG : Qdrant (Vector DB), BM25 + ko-sbert-nli (768d) + RRF 하이브리드, bge-reranker-v2-m3 ◦ Intent 분류 : KoELECTRA-base-v3 파인튜닝 (6-label, KNOWN_OVERRIDES 15개 + Rule Guide 2개) ◦ 문서 파싱 : Docling (디지털 PDF) + PaddleOCR (스캔 PDF) + python-docx ◦ 인프라 : AWS (EC2 + S3 + RDS), Docker Compose, GitHub Actions CI/CD, RunPod A100 80GB
설치 및 설정	1. 환경변수 설정 <code>.env</code> 파일을 프로젝트 루트에 생성 (OPENAI_API_KEY, DATABASE_URL, QDRANT_URL, GOOGLE_CLIENT_ID 등) 2. Docker로 실행 (권장) <pre>cd docker && docker-compose up -d # PostgreSQL + Redis + Qdrant + Backend + Frontend 5개 서비스 실행</pre> 3. 로컬 개발 환경 3.1. Backend 환경 (FastAPI) <pre>pip install -r requirements.txt cd backend && uvicorn app.main:app --reload --port 8000</pre> 3.2. Frontend 환경 (React + Vite)

```
cd frontend && npm install && npm run dev
```

4. 필요한 패키지

- Backend: fastapi, uvicorn, sqlalchemy, alembic, pyjwt, langchain, langgraph, qdrant-client, openai, anthropic, transformers, peft, docling, paddleocr
- Frontend: react, vite, zustand, @tanstack/react-query, tailwindcss, fullcalendar, framer-motion, lucide-react

5. DB 마이그레이션

```
cd backend && alembic upgrade head  
# 또는 python create_tables.py
```

6. Qdrant 규정 인덱싱

```
cd backend && python -m scripts.rebuild_qdrant
```

7. API 문서 확인

- Swagger UI : <http://localhost:8000/docs>
- ReDoc : <http://localhost:8000/redoc>

기본 사용법

★ 홈페이지 사용법

1. 로그인 / 회원가입

- main 화면 — 로그인 페이지 (이메일 + 비밀번호 또는 Google OAuth)
- 회원이 아닐 경우 → 회원가입 탭 (이름, 이메일, 팀 선택, 비밀번호)
- 로그인 성공 시 → 대시보드(/dashboard) 이동

2. 대시보드

- 인사말 배너 + 일정 타임라인 + 캘린더 + AI 챗 위젯 + 최근 문서 + Pipeline 위젯
- 편집 모드: 위젯 드래그앤드롭 배치, 추가/제거/초기화

3. AI 챗봇 (/chat) — 핵심 기능

- 자연어 질문 입력 → Intent 자동 분류(6개) → Agent 라우팅 → SSE 스트리밍 응답
- 규정 판단: "인턴에게 AWS 접근 줘도 돼?" → 다중 규정 교차 판단 + 근거 조항 + 대안 + 신뢰도
- 문서 처리: 문서 검색/QA(RAG) + 문서 생성(템플릿) + 문서 요약
- 일정 관리: "내일 오후 2시에 회의 잡아줘" → Google Calendar 등록 + Meet 링크 생성 + 메일 발송
- 카테고리 토글(전체/규정/문서/일정/일반), 규정 패널, 추천 질문
- 세션 관리: 사이드바에서 대화 세션 생성/전환/삭제, 대화 맥락 유지(최근 6건)

4. 문서 생성 (/document-generate)

- 시스템 템플릿 3종 (회의록/보고서/제안서) + 커스텀 DOCX 업로드
- 동적 폼 필드 → AI 내용 자동 채움 → 결과 미리보기 → DOCX/PDF 다운로드

5. 문서 관리 (/documents)

- 드래그앤드롭 업로드 → 자동 파싱(Docling+PaddleOCR) → AI 분석(카테고리/태그/요약)
- 검색(제목/내용/날짜) + scope 필터(회사/팀) + 상세 패널 + 삭제

6. 일정 관리 (/schedules)

- Calendar 탭: FullCalendar 월/주/일 뷰, Google Calendar 양방향 동기화
- Pipeline 탭: 프로젝트 카드(진행률/D-day/멤버), 칸반 보드 연결

	◦ Approvals 탭: 결재 현황 조회 ◦ Google/Slack 연동 모달: OAuth 2.0 연결/해제 7. 그 외 기능 ◦ Task Pipeline (/tasks): To Do → In Progress → Review → Done 칸반 보드 (드래그앤드롭) ◦ 결재 (/approvals): 10종 유형 결재 요청/승인/거절 + AI 체크리스트/추천 일정 ◦ 쪽지 (/messages): 사용자 간 쪽지 송수신 + 플로팅 팝업 + 30초 자동 갱신 ◦ 관리자 (/admin): 사용자/규정 CRUD + 통계/로그 조회 ◦ 마이페이지 (/mypage): 프로필 + 비밀번호 변경 + Google 4종 연동 관리 ◦ 다크모드, 반응형 UI, 플로팅 AI 챗봇 팝업 (모든 페이지)
확장 및 커스터마이징	1. LLM 프로바이더 교체 ◦ <code>ai/llm/factory.py</code> 에서 프로바이더 선택 (OpenAI / Anthropic / vLLM) ◦ vLLM + LoRA 핫스왑으로 sLLM 전환 시 코드 수정 최소화 (인터페이스 동일) 2. sLLM 파인튜닝 확장 ◦ Kanana-1.5-8B + LoRA (r=16, alpha=32) 기반 도메인 특화 학습 ◦ LoRA v1: 규정 판단 특화 / LoRA v2: 문서 생성 특화 / LoRA v3: 분석 특화 ◦ RunPod A100 80GB에서 학습 → HuggingFace Hub 업로드 → vLLM 서빙 3. Agent 추가 ◦ LangGraph StateGraph에 새 Agent 노드 추가 가능 (예: HR Agent, Finance Agent) ◦ Intent 분류 라벨 추가 + KNOWN_OVERRIDES 패턴 추가로 라우팅 확장 4. Google Workspace 확장 ◦ 현재 4종(Calendar/Tasks/Gmail/Sheets) → Drive, Docs 등 추가 연동 가능 ◦ <code>GoogleBaseService</code> 상속 구조로 신규 서비스 추가 용이 5. 온프레미스 배포 ◦ sLLM(vLLM) 전환 완료 시 외부 API 의존 없이 완전한 온프레미스 운영 가능 ◦ Docker Compose 기반 원클릭 배포 지원
결론	★ 성과 • LangGraph 기반 멀티 Agent 오케스트레이션 + SSE 실시간 스트리밍 웹 애플리케이션 구축 • FastAPI 백엔드(12 테이블) + React 프론트엔드(11+ 페이지) 풀스택 완성 • Intent 분류: KoELECTRA Test F1 97.88%, Adversarial F1 87.58%, 추론 7.9ms • RAG 하이브리드 검색(BM25 + Qdrant + RRF) 파이프라인 구현 • Google Workspace 4종 통합 연동 (Calendar + Tasks + Gmail + Sheets) • Kanana-1.5-8B LoRA 파인튜닝 (판단 v1: 정확도 83.5% → v3 진행중) • AWS EC2 CI/CD 배포 + Docker Compose 컨테이너화 완료 ★ 향후 발전 방향 • sLLM(vLLM) 완전 전환으로 외부 API 의존 제거 → 사내 데이터 보안 강화 • LoRA v3 판단 + v2 문서 파인튜닝 완료 후 성능 평가 및 모델 교체 • 복합 질문 처리 강화 (Smart Hybrid 아키텍처) • 멀티 Agent 협업 시나리오 확장 (규정 판단 → 문서 생성 → 일정 등록 연쇄) • 팀/부서별 맞춤 규정 학습으로 도메인 특화 정밀도 향상