시스템 구성도

작성일 : 2025.03.17.(월)
작성자 : 3팀 (신지용, 윤경은, 안혜빈, 문지영)

USER

사내 직원

회원가입
- e-mail
- name
- password

로그인
- e-mail
- password

Google OAuth 2.0

→ 자연어 입력

FRONTEND

React 18 (Vite)

상태관리: Zustand + TanStack Query
스타일: Tailwind CSS + Lucide Icons
스트리밍: EventSource (SSE)

화면 구성 (11 Pages)

대시보드 (통계 위젯)
AI 챗봇 (메인 채팅)
회의록 관리
문서 생성 / 문서 관리
일정 관리 (FullCalendar)
마이페이지
관리자 (사용자/규정/통계)
로그인 / 회원가입

응답 카드 UI

JudgmentCard (판단 결과)
DocumentCard (문서 결과)
ScheduleCard (일정 결과)
StreamingText (실시간)

↔ REST API + SSE Stream

BACKEND

FastAPI + SSE (StreamingResponse)

인증: JWT (PyJWT) + Google OAuth 2.0
암호화: AES-256
ORM: SQLAlchemy + Alembic

API Endpoints (/api/v1/*)

/chat/stream — 챗봇 + SSE
/auth — JWT + 소셜 로그인
/documents — 문서 CRUD + 생성
/meetings — 회의 관리
/schedules — 일정 CRUD
/calendar — Google Calendar
/tasks — Google Tasks
/gmail — Gmail 발송
/sheets — Google Sheets
/regulations — 규정 조회
/admin — 관리자 API

Internal Services

chat_service (세션/대화)
document_service (업로드/파싱)
template_service (문서 생성)
schedule_service (Google 통합)
statistics_service (통계/로그)
parsing_service (파싱 상태)

↔ Agent 호출

AI ENGINE

Intent Classifier (BERT 6-label)

`judgment` `doc_retrieve` `doc_generate` `schedule_add` `schedule_view` `general`

KNOWN_OVERRIDES (15개 패턴): 규칙 기반 intent 강제 전환
예) "규정 알려줘" → judgment 강제 매핑
멀티라벨 후처리 Rule (2개): judgment/doc_retrieve 경계 보정
총 17개 규칙 기반 보정 → knowledge_query 후처리 매핑 불필요

↓ confidence ≥ 0.85 → 라우팅 / < 0.85 → 재질문

LangGraph Orchestrator (StateGraph)

AgentState 관리 + 조건부 라우팅 + SSE 스트리밍

↓

Judgment Agent
규정 판단
- RAG 하이브리드 검색
- 다중 규정 교차 판단
- 근거 조항 + 대안 제시
- 3중 보조장치 검증 (환각탐지/조항검증/Confidence보정)

Document Agent
문서 처리
- 문서 생성 (템플릿 기반) 회의록/보고서/JD/제안서
- 문서 검색/요약/QA (doc_retrieve로 통합)
- 근거 인용 + RAG 연동

Schedule Agent
일정 관리
- 자연어 → 일정 등록
- 기간별 일정 조회
- Google Calendar 동기화
- Tasks + Gmail + Sheets (4개 서비스 오케스트레이션)

↓

RAG Pipeline (Judgment + doc_retrieve)

Query Refine → BM25 (키워드) → Vector Search (Qdrant + ko-sbert) → RRF 합산 → Reranker (bge-reranker-v2-m3) → Top-K 문서

Judgment: source="regulations" (사내 규정) **doc_retrieve:** source="documents" (업로드 문서)

↓

LLM Module (공통 인터페이스)

sLLM (메인)
Kanana-1.5-8B + LoRA
vLLM 서빙 (OpenAI 호환 API)
LoRA v1: 판단 | LoRA v2: 문서 | 일정: base

Fallback
GPT-4o-mini
sLLM 실패 시 자동 전환

문서 파서: Docling + PaddleOCR
규정 파서: 조문 기반 청킹

↔

DATA / EXTERNAL

PostgreSQL
- 회원정보 (User)
- Chat 세션/메시지
- 문서 + 파싱 상태
- 회의 + 요약
- 일정 (Schedule)
- 규정 / 템플릿
- 통계 로그

(12 Tables, Alembic 마이그레이션)

Qdrant (Vector DB)
- 규정 임베딩 (regulations)
- 문서 임베딩 (documents)

ko-sbert-nli (768d)

Redis (Cache)
세션 캐시

Google Services
- Google Calendar + Meet
- Google Tasks
- Gmail (알림/초대)
- Google Sheets (추적)

통합 OAuth 2.0 인증

Infra
- AWS EC2 + S3 + RDS
- Docker + Docker Compose
- GitHub Actions CI/CD
- RunPod A100 (학습)

응답 흐름: LLM 생성 → Response Formatter → PostgreSQL 저장 → SSE Streaming → Frontend 카드 UI 렌더링 → **답변(Answer)**