

Intent Classification 실험 요약 (팀 공유용)

1 . 실험 목적

사용자 입력을 8 개 Intent로 정확히 분류하여 각 Agent로 올바르게 라우팅하는 것이 목표.

→ Intent 오분류 = 잘못된 기능 실행

2 . 전체 데이터 구성

학습용 데이터

- 기본 데이터: 2, 2 9 9
- 경계쌍: 6 0 0

→ Stratified split

- Train: 2, 3 2 7
- Val: 2 8 5
- Test: 2 8 6

강건성 평가용 데이터

- Adversarial: 4 5 0
- 시나리오 테스트: 1 0 0

3 . 실험 흐름 (7 Stage)

Stage 1 — 데이터 생성 & 검수

- GPT + Claude 혼합 생성
- 클래스 불균형 최소화
- 데이터 누출 0 건

Stage 2 — Baseline 모델 비교

동일 조건에서 3 개 모델 비교 - KLUE BERT - KoELECTRA - DistilKoBERT

→ KoELECTRA 성능 우세

Stage 3 — Grid Search

- KoELECTRA 하이퍼파라미터 최적화
- 3 -seed 안정성 검증

➡ 데이터 품질 영향이 더 큼 확인

Stage 4 — 최종 모델 평가

Adversarial 포함 평가

모델 선택 기준: - Test F1  - Adversarial F1 

➡ 실전 강건성 기준으로 KoELECTRA 채택

Stage 5 — 오분류 분석 & 타겟 보강

오류 유형: - 짧은 문장 - 경계 intent - 과신되

타겟 데이터 98개 추가 후 재학습

➡ Adversarial F1 + 1.8%p 개선

Stage 6 — Label Smoothing

목적: 과신되 해결

결과: - F1 거의 동일 - 오답 confidence 감소

➡ Confidence 기반 clarify 라우팅 가능

Stage 7 — 라벨 품질 검증

오분류 수동 분석 결과: - 모델 오류: 3.7% - 라벨 애매/오류: 6.3%

➡ doc intent 성능 저하는 라벨 영향 큼 ➡ 소량 보강(25개)은 효과 없음 ➡ 최종 모델은 Stage 6 유지

4. 최종 성능

정량 성능

- Test F1 : 97.88%
- Adversarial F1 : 87.58%
- 추론 속도: 7.9ms

정성 평가 (시나리오 100개)

- 전체 정확도: 85%
 - normal: 100%
 - short: 93.3%
 - informal: 76%
-

5 . 서비스 적용 방식

Confidence 기반 라우팅:

- ≥ 0.85 → 자동 실행
- < 0.85 → 사용자 clarify

→ 오분류 시 잘못된 기능 실행 방지

6 . 핵심 인사이트

- 1 . 모델보다 데이터 보강이 성능 개선에 더 효과적
 - 2 . Test 성능보다 **Adversarial** 성능이 실전 지표
 - 3 . Label smoothing으로 과신된 문제 해결
 - 4 . doc intent 성능 문제의 주요 원인은 라벨 품질
-

7 . 한계 및 향후 계획

- doc 경계 데이터 대량 확보 필요
 - 슬랭 / 구어체 데이터 추가
 - 실서비스 로그 기반 재학습
 - Multi-intent 처리 확장
-

한 줄 요약

KoELECTRA 기반 Intent 분류기를 구축했고,
Adversarial F1 87.6%까지 개선했으며,
Confidence 기반 안전 라우팅이 가능해짐.