

0220_오프라인멘토링

[18:30 - 19:40]

대시보드

- 마감 임박 기준 설정
- 개인 / 그룹핑도 필요할 것 → 일정 공유 기능도 필요할 것

나에게 물어봐

-  가능 → “재택근무 규정 알려줘”인데 왜 나와
- 2시 회의 잡아줘 할때 더 많은 요소들이 들어가야 할 것
 - 몇 명, 어디서, 메일 전송 요청, 몇 시간, ... 필요해 보이는데 너무 단방향으로 끝남
 - LLM이랑 대화형으로 슬롯 채워지면 등록할 수 있도록
 - Human in the loop
- 이번 주 → 로직 확인 필요
 - LLM이 잘 못함
 - 라이브러리 같은 거 사용해서 시간 처리 필요함
 - 내일, 어제, ... 처리 가능하도록
- 대답 채팅에 마크다운 렌더링 안 됨
- 규정 데이터를 빨리 필요해 보임
- 미팅 질문하면 google meet 등록 되어있을 때만 나오는 건지 확인
- 음 .. 놓쳤다
- 멀티 턴은 제외하고 나중에 생각하기, 일단 분류만 하기
 - 유저의 의도 파악/ 쪼개기 먼저 처리 → 멀티턴 : 순서대로 문제 해결하기
 - 인메모리 디비 사용 / 이전 컨텍스트 요약해서 계속 저장하거나 이런 방식도 있음
 - 단일 질문부터 잘되도록 해결하기 step by step !!
- 일상대화는 빼고, 업무관련 대화만

일정

- 일정 등록할 때 메일 전송 ??

문서 생성

- 사용자가 템플릿만 올리는지, 속이 차 있는 걸 올리는지
- 사용 방식 고민해 보기
- 챗봇이랑 연결되면 good
- (문서 생성 탭에서 AI회의록 생성 버튼이랑 확대/축소 버튼이 겹침)

문서 관리

- 인쇄 기능 왜 ?
- 회사 문서 / 개인 문서 왜?
- 문서 분류는 사용자가 체크하는지, 알아서 분류되는지 → 체크하는 것이 좋아 보임

- Google 연동 버튼에서 gmail 발송 → gmail 수정하면 좋을 것 같음 (혜빈의 의견)
- 문서 추출해서 vector db에 넣고, 활용할 기능 확정

회의 관리

- Action item에 check 기능이 왜 필요한지
- 회의 관리에서 필요한 기능 확정 → 빨리 처리하고 문서 관리에 집중

관리자 설정

- 팀기능 추가하면 좋을 것 같다
 - 팀 권한 관리 etc.
 - 사소하지만 있으면 좋을 것

→ streamlit 냄새 마니 남

[20:00 - 20:40]

- 데이터
 - 꼭 필요한 거
 - 규정 문서 → 30개는 좀 적어보임
 -
- 문서 agent가 대답해야 하는 것
 - 규정 ...
 -

데이터

- LLM 몇 개를 학습시켜야 하는지
 - 우리가 만들 기능이 몇 개인지 정의하기 → 정확하게 우리가 만들 기능이 몇 개인지 !
 - 만든 데이터가 유의미한, 실제 데이터가 유의미한 점 파악해서 데이터 사용
 - 데이터는 문서 (챗봇이 답변을 위해 참고하는 문서 !)
 - 어떤 데이터가 들어있으면 도움이 될지 (모든 걸 만들어서 사용할 순 없음 → 의미 없음)

Document

- ① 요약 → 문서 type 3
- ② 생성 → 문서 type 3
- ③ Risk 생성
 - 어디에서 돌아가는가 - AI chatbot ? / 문서 생성 ? → 둘 다 !
 - 기능이 중복되는 데 인터페이스가 두 개여야 하는 이유?
 - chatbot에서 사용할 때는 번거롭지 않은지 / 기능 제외까지는 아님

④검색 QA

- 여러 문서에서 정보 알려주는 기능 .?
- 문서 type 3가지 정도 (회의록, ,)
- QA에서 중요한 건
 - 긴 글 안에서 우리의 쿼리와 관련된 중요한 문장만 뽑아서 답해주는 것 → 이걸 훈련 시키는 것
 - = 우리의 fine tuning 목적 !!

- ✓ 우리의 큰 기능은 두 가지 요약 LLM , 생성(QA)LLM
- ✓ 문서 agent의 전체적인 pipeline 그려보기 / workflow

- ✓ 눈에 보이는 게 없어서 헷갈림, 전체적인 뼈대를 그리기 ~

[21:00 - 22:30]

파인 튜닝

- 정량적인 것만 있는데, 정성적인 것도 있으면 좋을 것 같음
 - 이런거 해보니까 얼마 정도 올랐다
- 정량적인 것도 중요하지만, 정성적인 것도 항상 기록해 두면 좋음
 - 너무 자세하게는 아니고 정리해 두기 (수치 + 실제 시나리오 → 예시를 들어 근거를 보여줄 수 있도록)
 - 우리의 기준을 세워서 보여줄 수도 있지

LLM 튜닝

- 요약
- RAG

+ RAFT (2403.10131)

<https://arxiv.org/pdf/2403.10131>

- 더위 이슈 발생

+ <https://davidlds.tistory.com/100>

- 여유가 된다면 강화학습 공부 추천

[LLM 파인 튜닝 과정]

데이터 수집 → 데이터 전처리 : chunking, 노이즈 제거, deduplication(중복 제거) → 쿼리셋 만들기 → context 하나에 question/answer 형태로 나오게 → 학습 → 테스트 : 처음 베이스라인에 비해 뭐가 바뀌었는지, 무엇이 개선되었는지 확인 (정량) → 정성 평가 → (모델 개선하고 싶을 때) → "강화학습" / 하이퍼파라미터 실험 / 파인튜닝 한 번 더 ...

But,

- 튜닝이 원하는 형태로 잘 안됨
- 시나리오에서 실제로 확인될 만큼 성능이 좋아지지 않음

+ Ragas

<https://docs.ragas.io/en/stable/>

: RAG 평가에 실용적

(<https://blog-ko.superb-ai.com/rag-pipeline-performance-metrics-ragas-score-guide/>)

Tuning tool

+ wandb

<https://wandb.ai/site/ko/>

+ wandb sweep

<https://minimin2.tistory.com/188>

: 하이퍼 파라미터 튜닝

✓ 문서 agent: 멘토님이 말씀해 주신 것 토대로 승언 → 지용 인수인계

✓ 나머지도 workflow 잘 그려서 진행하기

일정

- Until 중간발표
 - 서론: 이런 문제를 개선하기 위해 이걸 만들기로 했다
 - 본론: 각각의 기능들 설명
 - 각 agent의 workflow 발표
 - 이 틀에 맞춰서 진행하고 있고, 이 정도 진행됐다
 - 실험 결과
 - Bert tuning
 - 앞으로 진행할 사항

중간발표에서는 페이지 보여주고 시연까진 필요 없음(미완이기에) - 자유

- 중간발표는 중간 점검 정도일 뿐, 부담 X

→ 발표 초안 (2월25일, 수)

